

Dokumentacja wstępna

Hanna Biegacz, Ada Jacyna

Treść zadania

Drzewo decyzyjne w zadaniu klasyfikacji miejsc rozcięcia w sekwencji DNA. Należy dopuścić alternatywę w testach, np. `if(atr12=='A' || atr12=='T')`. Istnieją dwa rodzaje miejsc rozcięcia sekwencji kodującej białko: donory i akceptory. Ich odnalezienie otwiera drogę do znalezienia eksonów, czyli sekwencji kodujących białka. Należy zaimplementować klasyfikator, następnie przeprowadzić jego trening i testowanie na 2 problemach:


1. szukanie donorów,
2. szukanie akceptorów.

Każdy ze zbiorów danych należy rozdzielić na trenujący i testujący lub zastosować walidację krzyżową. Zaimplementowany klasyfikator należy przebadac (wykonać eksperymenty).

Zrozumienie teoretycznego aspektu zadania

Donory to miejsca w DNA gdzie zaczyna się wycięty fragment DNA, intron - rozpoznawalny po sekwencji GT na początku fragmentu. **Akceptory** to miejsca gdzie intron się kończy - rozpoznawalne po sekwencji AG na końcu części DNA. Jedno miejsce nie może być jednocześnie donorem i akceptorem.

Na ilustracji widać schemat uproszczonego podziału DNA, w którym introny są wycinane, a sąsiadujące egzony łączone w ciągłą sekwencję. Miejsca donorowe i akceptorowe wyznaczają granice tych fragmentów, czyli punkty, w których następuje odpowiednie cięcie i łączenie.



Schemat 1. Schemat podziału DNA z wycinaniem intronów (źródło: Shutterstock)

Plan działania

Głównym celem projektu jest implementacja klasyfikatora opartego na drzewach decyzyjnych, który ma identyfikować dwa typy miejsc rozcięcia w sekwencji DNA: **donory i akceptory**. Każdy fragment DNA zostanie sklasyfikowany jako **donor / non-donor** lub **acceptor / non-acceptor**.

Zbiór danych

W projekcie wykorzystany zostanie gotowy zbiór danych z treści polecenia, podzielony na donory i akceptory. Zbiór donorów obejmuje 15-literowe sekwencje DNA (np. **CTCCGAAGTAGGATT**) wraz z informacją, czy są donorami. Analogicznie wygląda zbiór akceptorów, z tą różnicą, że sekwencje mają 90 znaków.

Zbiory trenujący, walidacyjny i testowy będzie wyłaniany przez losowy podział danych (np. 70/15/15), tak aby proporcje klas donorów i nie-donorów czy też akceptorów i nie-akceptorów zostały zachowane w każdej części.

Wykorzystanie algorytmów

Algorytmem, z którego skorzystamy, będzie zmodyfikowane pod zadanie **drzewo decyzyjne ID3**. Kryteriami podziału nie będą liczby, ale grupy liter na konkretnych pozycjach np. *“czy na pozycji 4 jest litera T albo litera A?”*. Pozwalamy na zbiory liter w celu umożliwienia alternatywy. Liście natomiast będą zawierały decyzję o typie klasy.

Aby poprawnie odczytać dane, przyjmujemy, że klasa przyjmuje wartości ze zbioru $C \in \{0, 1\}$.

1

GGTCTCGGTAAGTGC

0

CCCTGCAGTTTGGGT

Każdy przykład składa się z dwóch linii: etykiety klasy oraz ciągu nukleotydów (A, C, G, T) o stałej długości, ale innej dla akceptorów i dla donorów.

Jako miarę jakości podziału w drzewie wykorzystamy zysk informacyjny tzw. *Information Gain*, oparty na entropii:

$$E(S) = - \sum p(c) \log_2 p(c)$$

gdzie:

S to zbiór

c to klasa

$p(c)$ to ułamek przykładów klasy c w zbiorze S.

Wzór na zysk:

$$IG(S, a) = E(S) - \sum_{v \in \text{wartości}(a)} \frac{|S_v|}{|S|} E(S_v)$$

a - dany atrybut

$|S_v|$ - liczba elementów w podzbiorze S_v

$|S|$ - liczba wszystkich elementów w zbiorze S

$\text{wartości}(a)$ - zbiór wszystkich możliwych wartości atrybutu a

Algorytm:

- Rozpoczynamy od całego zbioru danych umieszczonego w węźle korzenia.
- Pętla podziału dla każdego węzła niespełniającego kryteriów stopu:
 - Dla wszystkich atrybutów generujemy wszystkie możliwe binarne podziały zbioru $\{A, C, G, T\}$ np. $\{A, C\}$ vs $\{G, T\}$
 - Obliczamy wartości zysku informacyjnego tych podziałów
 - Wybierany jest ten podział, który daje największy zysk informacyjny
 - Dane dzielone są na dwie grupy: spełniające warunek (lewa gałąź) i nie spełniające (prawa);
 - Proces powtarzany dla obu grup rekurencyjnie

Warunki stopu algorytmu:

- wszystkie przykłady w węźle należą do tej samej klasy
- brak atrybutów odróżniających => niespójne dane (dwa takie same ciągi dają inną klasę)
- przekroczono głębokość drzewa (parametr dostosowywany)

Przykład obliczeniowy

Załóżmy, że w danym węźle mamy zbiór 5 sekwencji DNA. Porównujemy pierwszy atrybut każdej z nich.

ID	Pozycja 1 (Atrybut)	Klasa
1	A	1
2	A	1
3	T	1
4	C	0
5	G	0

- Wchodzimy w kolejny krok algorytmu, mianowicie obliczenie entropii początkowej. Mamy 3 donory (3 pola klasy 1) i 2 nie-donory (klasa 0). Entropia:

$$E(S) = -\frac{3}{5} \log_2 \frac{3}{5} - \frac{2}{5} \log_2 \frac{2}{5} \approx 0.971$$

- Sprawdzamy przykładowy podział jakiegoś z atrybutów.
 Wybieramy np. Czy na pozycji 1 jest {A, T}? Następnie dzielimy dane na dwie grupy:
 Grupa TAK: Dla $ID \in \{1, 2, 3\}$, Entropia dla tej grupy: $E = 0$, ponieważ wszystkie wartości klas przykładów tej grupy wynoszą 1.
 Grupa NIE: Dla $ID \in \{4, 5\}$, Entropia dla tej grupy: $E = 0$, j.w. (klasa 0)

- Obliczamy zysk informacyjny:

$$IG = 0.971 - \left(\frac{3}{5} \cdot 0 + \frac{2}{5} \cdot 0 \right) = 0.971$$

Wniosek: Ten podział daje maksymalny zysk i.e. redukuje entropię do zera, więc algorytm go wybierze.

Miary jakości klasyfikatora

W celu oceny jakości klasyfikatora wykorzystamy następujące parametry:

- **accuracy** → dokładność, miara określająca procent wszystkich poprawnie sklasyfikowanych przykładów.
- **confusion matrix** → tabela pomyłek, macierz, która szczegółowo pokazuje rozkład decyzji klasyfikatora. Pokazuje liczbę poprawnie sklasyfikowanych przykładów oraz pomyłek między klasami,
- **recall** → czułość, reprezentująca odsetek przypadków typu *false negative*, a więc kiedy klasyfikator nie rozpoznał klasy chociaż powinien.
- **precision** → precyzja, pozwala określić jak często w klasyfikacji występują *false positives*.

Plan eksperymentów

W czasie pracy nad klasyfikatorem niezbędne będą eksperymenty w celu określenia najlepszych parametrów drzewa. Dla każdej zmiany parametrów będzie wykonany pomiar jakości i na tej podstawie wyłoniony zostanie najlepszy zestaw.

Elementy algorytmu do przetestowania:

- **maksymalna głębokości drzewa**, np. $\{\infty, 15, 10, 8, 6, 4\}$
- **warunek zatrzymania**, np. minimalny *information gain* wymagany do utworzenia kolejnego podziału (większy niż zero 0),
- **obsługa równoważnych podziałów**, sprawdzimy różne strategię sytuacji, w których kilka podziałów daje identyczny zysk informacyjny, np. wybór pierwszego, losowego albo podziału o mniejszej liczbie elementów w gałęzi,
- **stosunek podziału zbioru danych**, proporcje między zbiorem treningowym, testowym i walidacyjnym, np. 70/15/15, 70/20/10 czy 60/20/20.